

Planeamiento óptimo del Manejo Integrado de Malezas

Lucia Damiani^{1*}, Franco A. Molinari^{2,3}, Guillermo R. Chantre^{2,4}, Aníbal M. Blanco¹

¹Planta Piloto de Ingeniería Química, Universidad Nacional del Sur (PLAPIQUI-CONICET),
8000 Bahía Blanca, Buenos Aires, Argentina

²Departamento de Agronomía, Universidad Nacional del Sur, San Andrés 800, 8000 Bahía
Blanca, Argentina.

³Comisión de Investigaciones Científicas de la Provincia de Buenos Aires (CIC)

⁴Centro de Recursos Naturales Renovables de la Zona Semiárida (CERZOS-CONICET), 8000
Bahía Blanca, Argentina

*ldamiani@plapiqui.edu.ar

Resumen. En el presente trabajo se propone optimizar un modelo matemático de simulación multianual de escenarios de Manejo Integrado de Malezas (MIM), el cual representa la interacción de la maleza *Avena fatua* L. en competencia con trigo y cebada, un sistema productivo típico del sudoeste bonaerense. Con este objetivo se desarrolló una herramienta propia basada en el optimizador estocástico por enjambre de partículas (PSO), al cual se le agregaron técnicas para el manejo de restricciones, variables binarias y múltiples objetivos. El estudio propuesto tiene en cuenta tanto el impacto ambiental como el beneficio económico y permite estimar anualmente: (i) el tipo de cultivo a sembrar; (ii) su densidad de siembra; (iii) el tipo de cultivar; (iv) la fecha de siembra; (v) el método de control de la maleza y la (vi) fecha de aplicación del control.

Palabras Claves: optimización, MIM, impacto ambiental y económico

1 Introducción

El modelo bio-económico propuesto en [1] permite simular los efectos económicos y medioambientales que podrían ocasionar diferentes estrategias de control sobre la dinámica demográfica de la maleza *Avena fatua* L. cuando compete con trigo o cebada en un horizonte de 5 años en un sistema productivo típico del sudoeste de la provincia de Buenos Aires. Ese modelo permite simular un subconjunto finito de escenarios o casos de estudio que representan posibles situaciones que se podrían dar en la práctica. Sin embargo, la cantidad de estrategias del Manejo Integrado de Malezas (MIM) a lo largo de unos pocos años es enorme, incluso para un modesto número de cultivos y alternativas de control. Para poder explorar sistemáticamente el extenso espacio de posibles opciones de manejo con el fin de hallar nuevas y mejores soluciones, surgió la necesidad de optimizar dicho modelo.

Al hablar de optimización se hace referencia al proceso de encontrar la combinación de variables que minimicen o maximicen uno o más criterios de desempeño del sistema o funciones objetivo, respetando una serie de restricciones de igualdad y desigualdad.

Para optimizar el modelo bio-económico descrito en [1] se requiere contar con un optimizador mixto entero no lineal multi objetivo (MINLP-MO, por sus siglas en inglés), ya que el problema MIM cuenta con restricciones, variables binarias y múltiples objetivos (se considerarán criterios de evaluación medioambientales y económico).

En general, un problema de optimización multiobjetivo que minimice NFO funciones objetivo, m variables continuas y n variables binarias, puede describirse matemáticamente según (1):

$$\begin{aligned} &\text{Minimizar } \mathbf{f}(\mathbf{x}, \mathbf{y}) = (f_1(\mathbf{x}, \mathbf{y}), \dots, f_k(\mathbf{x}, \mathbf{y}), \dots, f_{NFO}(\mathbf{x}, \mathbf{y})) \\ &\text{Sujeto a:} \\ &\quad \mathbf{h}(\mathbf{x}, \mathbf{y}) = 0; \mathbf{g}(\mathbf{x}, \mathbf{y}) \leq 0; \mathbf{x}^{lo} - \mathbf{x} \leq 0; \mathbf{x} - \mathbf{x}^{up} \leq 0; \mathbf{y} \in (0,1) \end{aligned} \quad (1)$$

Donde $\mathbf{f}(\cdot)$ son las funciones objetivo a optimizar; \mathbf{x} e \mathbf{y} son los conjuntos de variables de optimización continuas y binarias respectivamente; $\mathbf{h}(\cdot)$ y $\mathbf{g}(\cdot)$ representan las restricciones de igualdad y desigualdad respectivamente y los parámetros \mathbf{x}^{lo} y \mathbf{x}^{up} son los límites inferiores y superiores de las variables continuas.

La optimización numérica aplicada a modelos agronómicos de interacción cultivo-maleza ha sido recibido cierta atención en la literatura. Una revisión reciente de las principales contribuciones puede encontrarse en [2].

2 Materiales y Métodos

2.1 Modelo de simulación

El modelo de simulación descrito en [1] representa cómo inciden los efectos de diferentes estrategias de control sobre la dinámica demográfica de la maleza anual *Avena Fatua* L. en competencia con cereales de invierno (trigo-cebada) en un plan de rotación multianual. Específicamente el modelo permite estimar: (1) la dinámica demográfica de la maleza teniendo en cuenta las estrategias de control seleccionadas para cada año; (2) el nivel de competencia cultivo-maleza; (3) el rendimiento esperado del cultivo según la competencia con la maleza y la estrategia de manejo utilizada; (4) distintos indicadores económicos y ambientales.

Cabe recordar que, en la simulación llevada a cabo en [1], con el fin de mitigar el avance de la maleza se consideraron controles en presembrado y postemergencia. En el primer caso, siempre se realizan dos controles, uno en barbecho corto y otro en barbecho largo, que pueden ser químicos (glifosato) o mecánicos (labranza). En cambio, en postemergencia se puede optar entre pinoxaden o diclofop-metil (dependiendo de si se siembra cebada o trigo respectivamente) o ningún tipo de acción. También, se debe especificar la densidad de siembra del cultivo, que puede variar entre 250-280 plantas/m² si se siembra cebada o 200-400 plantas/m² si se trata de trigo. Además, en el caso del trigo, se contempla la posibilidad de sembrar un cultivar altamente competitivo o uno estándar. La diferencia entre ambos cultivares es que el estándar tiene una mayor pérdida de rendimiento por maleza, aunque potencialmente alcanza un área foliar máxima y un rendimiento potencial del cereal mayor que el cultivar altamente competitivo.

Para realizar la evaluación económica, en el modelo bio-económico se determinan dos indicadores: el margen bruto anual y el valor presente neto. El primero considera los beneficios por la venta del cereal y las erogaciones de dinero debido a diversos gastos (siembra del cultivo, métodos de control de maleza, cosecha y comercialización del cereal, así como su limpieza). Por otro lado, el valor presente neto (*VPN*), al tener en cuenta el valor temporal del dinero, permite actualizar (mediante una tasa de interés determinada) todos los flujos de dinero futuros al momento actual. De esta manera es posible evaluar la viabilidad económica financiera de las diferentes alternativas que se presentan y compararlas entre sí.

Asimismo, en el modelo reportado en [1] se debe recurrir a buscar las fechas fenológicas del cultivo en el software CRONOS¹ previo a iniciar la simulación. Para evitar recurrir a simulaciones externas, se buscó la manera de relacionar automáticamente dichas fechas. Una forma práctica de hacerlo es a través del tiempo térmico acumulado (*TTA*) que también proporciona CRONOS para ambos cultivos. Éste informa los *TTA* necesarios para alcanzar la emergencia, el periodo crítico y la madurez fisiológica a partir de la fecha de siembra. De esta forma, sólo es necesario especificar cuándo se siembra el cereal para estimar las fechas de cada una de las etapas fenológicas, las cuales son requeridas como datos de ingreso por el modelo bio-económico.

2.2 Herramienta de optimización

En este trabajo se decidió utilizar la optimización por enjambre de partículas (PSO por sus siglas en inglés) como metodología de optimización base, por ser relativamente sencilla de implementar y a la vez, porque se ha reportado en la literatura un buen rendimiento en diversas aplicaciones prácticas [3, 4]. Además, se consideró su gran flexibilidad para ser hibridada y extendida, lo que permite ampliar su rango de aplicaciones al incorporarle técnicas que admitan manipular problemas con restricciones, múltiples objetivos y variables binarias.

Todas estas cualidades la tornan una metodología atractiva para optimizar el modelo de simulación cultivo-maleza descrito en la sección anterior. A continuación, se presenta brevemente, el optimizador desarrollado. Cabe aclarar que tanto el optimizador como el modelo cultivo-maleza se programaron en el lenguaje de código abierto Python.

Optimización continua por Enjambre de Partículas (PSO)

PSO pertenece a la familia de las metaheurísticas y fue propuesta por [5], inspirándose en la conducta de comunidades de individuos cuando buscan alimentos (enjambres de insectos, cardúmenes de peces, etc.). En esta técnica, cada individuo forma parte de una población de posibles soluciones candidatas que se mueven en el espacio de búsqueda

¹ <http://cronos.agro.uba.ar/>

guiándose a través de reglas sencillas para modificar su ubicación. Estas reglas consideran la mejor posición local encontrada por cada individuo y la mejor posición global hallada por todo el enjambre a medida que recorre la región de búsqueda.

El mejor óptimo global y el mejor óptimo local se van actualizando cada vez que se descubren nuevas y mejores posiciones. Asimismo, la velocidad y posición de las partículas se modifican iterativamente hasta que se cumple algún criterio de terminación (en este trabajo se adoptó como criterio un número máximo de iteraciones). El PSO posee varios parámetros que es necesario definir, entre los que se destacan cantidad de partículas (N), constante de aceleración cognitiva ($c1$), constante de aceleración social ($c2$), peso de inercia (w) e iteraciones máximas ($k_{\text{máx}}$).

PSO: Tratamiento de restricciones

Generalmente, la gran mayoría de los problemas de optimización poseen restricciones de igualdad y desigualdad que limitan la región factible. Sin embargo, el PSO no posee un tratamiento explícito de las mismas, debido a que tanto el mejor local como el global se refieren implícitamente a soluciones factibles. Por lo tanto, para optimizar problemas con restricciones en este trabajo se adoptó el método TAV [6] debido a que resulta una propuesta práctica, que evita la reformulación o reducción de restricciones y es mucho menos dependiente de la elección de nuevos parámetros que otras técnicas populares.

En [6] se plantea agrandar temporalmente la región factible al relajar las restricciones de igualdad y desigualdad. A medida que las partículas comienzan a ingresar a esa región relajada, ésta empieza a disminuir hasta convertirse en la región factible original, es decir, la que tiene en cuenta todas las restricciones del problema.

La implementación del PSO con esta metodología se testeó en [3] aplicándolo sobre diferentes funciones benchmark de distinta complejidad, obteniendo un buen rendimiento general en todos los problemas investigados.

PSO: Tratamiento de variables binarias

Para optimizar el modelo bio-económico de [1], fue necesario incluir también un tratamiento de variables binarias, dado que existen decisiones del MIM que requieren definir si se toma o no una determinada acción. Para ello, en este trabajo se optó por implementar la técnica “Angle Modulation”, propuesta por [7], debido a su generalidad y facilidad para ser incorporada al PSO, así como también por su aplicación exitosa, reportada sobre problemas de diferente dificultad.

Este método utiliza el PSO para optimizar cuatro coeficientes (a, b, c, d) en el espacio continuo que luego, al introducirse en una función trigonométrica simple, genera una posible solución al problema binario original. Esto evita la complejidad combinatoria típica de exploración de tipo Branch & Bound aunque no se garantiza una exploración exhaustiva del árbol de opciones.

PSO: Tratamiento de múltiples objetivos

Debido a que se pretende tener en cuenta tanto el impacto ambiental como el económico al realizar la optimización del modelo bio-económico de [1], fue fundamental añadir al PSO una técnica para resolver problemas multi-objetivo. En el presente trabajo se eligió el método basado en el frente de Pareto, dado que éste permite sistematizar en gran medida el procedimiento de cálculo reduciendo a la vez la subjetividad y arbitrariedad en el tratamiento de los diferentes objetivos.

La frontera de Pareto se basa en que el algoritmo de optimización encuentre y exponga muchas de las soluciones pertenecientes a la región donde al mejorar uno de los objetivos empeoran los restantes. De esta manera, el usuario puede observar, evaluar y comparar las diferentes soluciones y decidir cuál de ellas aceptar, según su conocimiento, al priorizar en ese momento cierto objetivo en detrimento de los demás [8]. La frontera de Pareto se almacena en un archivo externo A, cuya dimensión es también un parámetro a establecer por el usuario (dimA).

2.3 Optimización del modelo de simulación cultivo-maleza

La metodología descrita en la sección anterior se utiliza para encontrar la mejor configuración del conjunto de variables de decisión (magnitudes que son controladas y determinadas por el optimizador). Las mismas se alimentan al simulador con el propósito de optimizar una cierta función objetivo o combinación de funciones objetivo, calculadas a través del modelo. Es decir, con las salidas provistas por el modelo de simulación, el PSO propone nuevos valores para las variables de entrada al modelo cultivo-maleza con el objetivo de mejorar progresivamente los resultados (Fig. 1).



Fig. 1. Sistema de asistencia a la toma de decisiones agronómicas

El ciclo que conecta el PSO con el modelo de simulación se repite sucesivamente hasta que se cumple el criterio de terminación del algoritmo (definido en este caso como un máximo número de iteraciones). En ese momento, se obtienen los resultados finales del optimizador con la mejor combinación de variables que minimicen (o maximicen) la/s

función/es objetivo y con los resultados propios de simular el sistema cultivo-maleza con dichas variables.

De esta manera, el PSO determina las variables de decisión que pueden ser continuas (si son números reales comprendidos entre un límite inferior y superior) o binarias (si valen uno o cero cuando se trata de acciones que ocurren o no, respectivamente). En la Fig. 2 se resumen las variables de decisión propias del modelo bio-económico planteadas en [1].

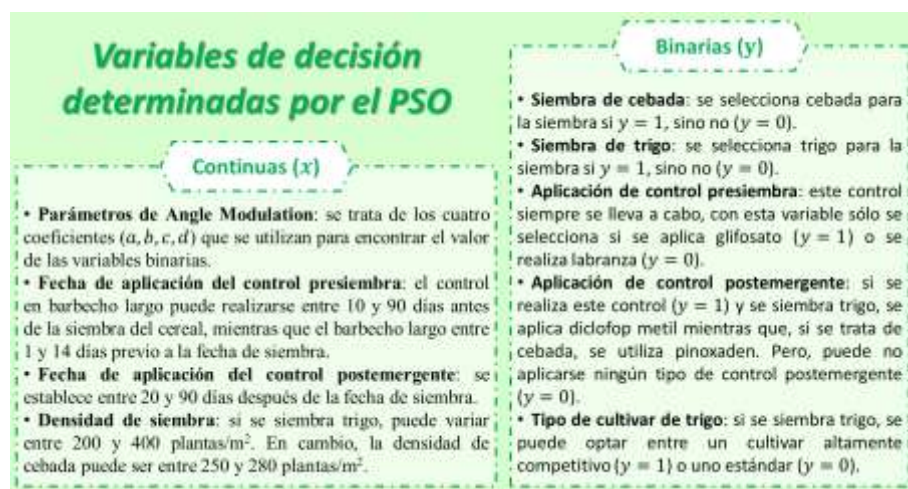


Fig. 2. Variables de decisión

3 Resultados

En esta sección se presentan diversos casos de optimización en los cuales el modelo bio-económico presenta los mismos parámetros utilizados en los estudios de simulación de [1] (*Avena fatua* L. en competencia con trigo o cebada en un horizonte de 5 años en un sistema productivo típico del sudoeste de la provincia de Buenos Aires). En todos los escenarios el horizonte de tiempo considerado corresponde al período 2014-2018, con los datos climáticos y perfiles de emergencia de la maleza correspondientes. Cada caso difiere en la función objetivo y/o restricciones, de esta manera, se busca encontrar las mejores soluciones de acuerdo a distintos intereses.

A continuación, se detallan los dos casos propuestos, describiendo las funciones objetivo utilizadas y los resultados obtenidos por el PSO al realizar la optimización del modelo agronómico. La misma se ejecutó en una computadora Intel(R) Core (TM) i7-3537U CPU @ 2.00GHz 2.50GHz con una memoria RAM de 8GB. Los parámetros del PSO para todas las optimizaciones realizadas son: $N = 100$, $c_1 = 1,5$; $c_2 = 1,5$; $w = 0,75$; $k_{\max} = 2500$ y $\dim_A = 20$. Para la cantidad de iteraciones máximas adoptada el tiempo de optimización demandado es de aproximadamente 11,20 h.

3.1 CASO I

En este caso se optimizó el modelo bio-económico en base a tres funciones objetivo (F) dadas en (2). La primera (f_1) es el indicador económico, basado en el valor presente neto (VPN) a lo largo del periodo de tiempo considerando una tasa de descuento del 15%. Las funciones objetivo f_2 y f_3 son el índice de labranza ($Indice_T$) y el de herbicidas ($Indice_P$) respectivamente [9]. Estos indicadores se incluyen con el objetivo de evaluar las consecuencias medioambientales del caso propuesto. Cuanto mayor es el valor de estos índices, menor es el impacto ambiental producido por los controles.

$$F \begin{cases} f_1 = -VPN \\ f_2 = -Indice P \\ f_3 = -Indice T \end{cases} \quad (2)$$

En la Fig. 3 se exhiben las doce soluciones del frente de Pareto obtenido al optimizar el modelo agronómico del CASO I. La misma muestra, a través de un gráfico de dispersión unido por líneas, el VPN y a través de gráficos de barra los índices de herbicidas ($Indice P$) y de labranza ($Indice T$).




Fig. 3. Resultados optimización CASO I

El archivo de salida del PSO se lo resumió en la Tabla 1 excluyendo las fechas de siembra del cultivo y aplicación de los métodos de control. En columna “Soluciones” se identifica cada una de las soluciones (S) del frente de Pareto; en “Cultivo” se especifica si se siembra cebada (C), trigo estándar (T-E) o altamente competitivo (T-AC); en “Densidad” se detalla la densidad de siembra del cultivo en [ind/m²]; la columna “Control” se divide en “Pre.” que hace referencia al control de malezas presiembra

(barbecho) que puede ser labranza (L) o glifosato (G) y “Post.” que define el control postemergente que puede ser diclofop-metil (D) si se siembra trigo o pinoxaden (P) en el caso de cebada.

En la Tabla 1 se observa que el plan de manejo correspondiente a las diferentes soluciones propone la siembra de cebada en cuatro o más de los cinco años del horizonte de planeamiento, a excepción de S2 que establece dos siembras de trigo. Esto podría asociarse a la mayor capacidad competitiva de la cebada frente al trigo. La cebada logra una competencia más temprana con la maleza y, a su vez, genera rápidamente condiciones de alta competencia durante un mayor período.

Dado que se parte de un banco inicial grande (2000 semillas/m²) parece lógico que se asigne gran parte del período, en particular al inicio, a cultivos más competitivos para reducir la población de malezas. Esto demuestra por qué en el año 2014, cuando la infestación de malezas es mayor, se propone la siembra de cebada.

En el caso del trigo, sólo tres soluciones proponen sembrarlo (S2, S4 y S6). En S2 se elige trigo altamente competitivo en 2015, cuando la competencia con la maleza es mayor, mientras que en 2018 se selecciona un cultivar estándar. Por otro lado, S4 y S6 siembran solo una vez trigo en los cinco años del horizonte de planeamiento (en 2017 y 2015 respectivamente), en ambos casos optan por trigo estándar.

Tabla 1. Resultados optimización CASO I

Soluciones	2014					2015					2016					2017					2018				
	Cultivo	Densidad	Control			Cultivo	Densidad	Control			Cultivo	Densidad	Control			Cultivo	Densidad	Control			Cultivo	Densidad	Control		
			Pre.	Post.				Pre.	Post.				Pre.	Post.				Pre.	Post.				Pre.	Post.	
S1	C	262	L	P		C	251	L	-		C	255	L	-		C	268	L	-		C	268	L	-	
S2	C	267	L	P	T-AC	C	261	G	-		C	262	L	-		C	267	L	-		T-E	280	G	-	
S3	C	259	G	-		C	269	L	-		C	268	L	-		C	264	L	-		C	264	L	-	
S4	C	255	L	P		C	250	G	-		C	251	G	-		T-E	310	G	-		C	261	G	-	
S5	C	275	G	P		C	260	G	-		C	253	L	-		C	274	L	-		C	267	G	-	
S6	C	254	L	P	T-E	C	233	L	-		C	250	L	-		C	267	G	-		C	266	L	-	
S7	C	277	G	-		C	270	G	-		C	265	G	-		C	276	L	-		C	262	L	-	
S8	C	275	L	-		C	268	L	-		C	276	L	-		C	274	L	-		C	274	L	-	
S9	C	274	G	-		C	259	G	-		C	270	G	-		C	254	G	-		C	265	G	-	
S10	C	268	G	-		C	267	G	-		C	266	G	-		C	251	G	-		C	259	L	-	
S11	C	253	G	-		C	269	G	-		C	271	L	-		C	261	L	-		C	272	L	-	
S12	C	260	G	P		C	270	G	-		C	270	G	-		C	261	G	-		C	258	G	-	

En cuanto al control presiembra, en la mayoría de las soluciones se suele alternar entre labranzas y control químico. Sin embargo, en aquellas soluciones que aplican glifosato en cuatro o cinco de los años de estudio (S4, S9, S10 y S12) se obtienen mejores VPN que cuando se realiza esa misma cantidad de labranzas (S1, S3, S6 y S8). Estos resultados eran esperables, ya que la labranza es mucho más costosa y su eficiencia respecto del control de la maleza apenas supera en un 1% a la del glifosato, además de provocar un gran impacto ambiental por efecto de la erosión del suelo.

Asimismo, se puede apreciar que la mitad de las soluciones (S3, S7, S8, S9, S10 y S11) no recomiendan la aplicación de herbicidas postemergentes, controlando las malezas con el tipo de cultivo a sembrar, la fecha de siembra, densidad y los herbicidas preemergentes de uso frecuente. Sin embargo, es evidente que estas opciones priorizan

un menor impacto ambiental frente a la obtención de un rédito económico, ya que los *VPN* alcanzados varían entre 93 y 202 USD/ha (Fig. 3), siendo un rango más bajo, en líneas generales, que las soluciones que aplican un control postemergente, cuyo *VPN* se encuentra entre 154 y 321 USD/ha. Las seis soluciones que aplican un control postemergente (S1, S2, S4, S5, S6 y S12) solo lo hacen una vez y siempre en el primer año de estudio (2014), cuando la infestación de malezas es mayor.

A continuación, se describirán en detalle a través de las figuras que representan la dinámica poblacional de AVEFA y el factor de competencia de los cultivos, las soluciones del frente de Pareto que alcanzaron los mejores *VPN*, e índices *T* y *P*.

Dentro del conjunto de soluciones, S12 presenta el mayor *VPN* (321 USD/ha). Esta estrategia establece la siembra de cebada en todo el horizonte de planeamiento. Como control presembrado se selecciona siempre glifosato, motivo por el cual se alcanza el máximo valor del índice *T* (5,00), ya que nunca se realiza control mecánico. En cuanto al control postemergente, solo se propone la aplicación de un herbicida en el primer año (2014), cuando la infestación de malezas es máxima. Debido a que se aplican controles químicos presembrado y postemergentes, el índice *P* es el peor (más bajo) del frente de Pareto, pero permite un control más eficiente de AVEFA, ya que en competencia con el cultivo (por debajo de la curva FC) nunca supera los 50 ind/m² (Fig. 4).




Fig. 4. Dinámica poblacional de AVEFA (P: Plántula, VT: Vegetativo Temprano, VA: Vegetativo Avanzado, RI: Reproductivo Inicial) y factor de competencia (FC) de S12 – CASO OI

Al igual que S12, S9 alcanza el mejor índice *T* (porque nunca se realiza labranza en presembrado) y también propone siembra de cebada en todos los años analizados. La principal diferencia radica en que S9 no aplica control postemergente, por eso su índice *P* es algo mejor que el de S12. Esta estrategia de control resulta ser más deficiente que la anterior, lo cual se evidencia en la Fig. 5, en donde la dinámica poblacional de la maleza alcanza picos cercanos a los 240 ind/m² en competencia con el cereal. Esta es la razón por la cual S9 logra sólo el 62% del mejor *VPN* del frente de Pareto.




Fig. 5. Dinámica poblacional de AVEFA (*P*: Plántula, *VT*: Vegetativo Temprano, *VA*: Vegetativo Avanzado, *RI*: Reproductivo Inicial) y factor de competencia (*FC*) de S9 – CASO OI

Por su parte, S8 logra el mejor (máximo) índice *P*, dado que solo realiza labranzas como control presiembra y no aplica controles postemergentes. La Fig. 6 demuestra que esta estrategia de control es mejor que S9, dado que los picos de maleza alcanzan un máximo de 200 ind/m² (en competencia con cebada) en 2015, lo que evidencia que las fechas establecidas para el control y la siembra, junto con la densidad de siembra, son más adecuadas que las de la solución anterior. Sin embargo, el costo del control mecánico es más elevado que el de control químico en presiembra, lo que repercute directamente en el margen bruto de cada año, y conlleva a que S8, dentro de todo el frente de Pareto, sea la solución que consigue el menor *VPN*.




Fig. 6. Dinámica poblacional de AVEFA (*P*: Plántula, *VT*: Vegetativo Temprano, *VA*: Vegetativo Avanzado, *RI*: Reproductivo Inicial) y factor de competencia (*FC*) de S8 – CASO OI

3.2 CASO II

Este experimento persigue representar una posible táctica agronómica que refleje prácticas y objetivos más aproximados a los tradicionales empleados en la zona bajo estudio. Como la labranza es una técnica relativamente poco utilizada en los últimos tiempos, se decidió incorporar una restricción para obligar al sistema a elegir solo la aplicación de glifosato como método de control presiembra en los cinco años analizados.

Como indicador de impacto medioambiental se empleó en este caso el índice *EIQ* [10]. De esta manera, el problema de optimización planteado queda definido según (3).

$$F \left\{ \begin{array}{l} f_1 = -VPN \\ f_2 = EIQ \end{array} \right. \quad \text{Sujeto a:} \quad \left. \begin{array}{l} h_1 = Cantidad_{LabranzaTOTAL} = 0 \end{array} \right. \quad (3)$$

A diferencia del caso anterior, en esta ocasión la frontera de Pareto (Fig. 7) se compone sólo de cuatro soluciones, dado que no se encuentran otras estrategias que provoquen alguna mejoría en al menos uno de los objetivos. Esto sucede ya que en este caso no se debe decidir qué tipo de control presiembra se llevará a cabo y, además, sólo existen dos funciones objetivo para guiar la búsqueda.




Fig. 7. Resultados optimización CASO II

La Tabla 2, que detalla cada una de las soluciones del frente de Pareto alcanzado luego de optimizar el CASO OII muestra que, nuevamente, todas ellas proponen la siembra de cebada en una mayor cantidad de años que de trigo. Además, se vuelve a comprobar que, si se determina sembrar trigo en los primeros años, se selecciona un cultivar altamente competitivo para controlar mejor la maleza (S3), mientras que, si se lo elige para

los últimos años, se opta por un cultivar estándar con mayor rendimiento potencial y menor capacidad de competencia (S1 y S4). Asimismo, S4 permite visualizar cómo una mayor cantidad de aplicaciones de herbicidas no conduce directamente a obtener el mejor *VPN* (alcanza el 69% del más alto), pero sí repercute en un mayor impacto ambiental (aunque no el máximo, dado que una aplicación de diclofop incide más en el *EIQ* que dos de pinoxaden, como se verifica en el *EIQ* de S3).

Tabla 2. Resultados optimización CASO II

Soluciones	2014				2015				2016				2017				2018			
	Cultivo	Densidad	Control		Cultivo	Densidad	Control		Cultivo	Densidad	Control		Cultivo	Densidad	Control		Cultivo	Densidad	Control	
			Pre.	Post.			Pre.	Post.			Pre.	Post.			Pre.	Post.			Pre.	Post.
S1	C	257	G	P	C	258	G	-	C	260	G	-	T-E	310	G	-	T-E	242	G	-
S2	C	268	G	-	C	266	G	-	C	254	G	-	C	264	G	-	C	266	G	-
S3	T-AC	385	G	D	T-AC	301	G	-	C	254	G	-	C	262	G	-	C	272	G	-
S4	C	266	G	P	C	266	G	P	C	253	G	-	C	261	G	-	T-E	386	G	-

De las cuatro estrategias que brinda el CASO OII se presentan, a continuación, la dinámica poblacional de AVEFA y el factor de competencia de los cultivos de las soluciones S3 y S2 que son las que logran el mejor *VPN* y menor *EIQ* respectivamente.

La solución S3 (Fig. 8) propone la siembra de trigo altamente competitivo los primeros dos años, mientras que en los últimos tres opta por cebada. Como control postemergente solo realiza una aplicación el primer año, el de mayor infestación. Esta estrategia controla eficazmente a la maleza, ya que en el período de competencia con el cultivo los picos de densidad se mantienen por debajo de 30 ind/m² (a excepción del 2014, donde el pico de 95 ind/m² es intervenido con el diclofop-metil), lo que permite alcanzar los mejores rendimientos del cultivo a costa de ser la propuesta con mayor *EIQ*.




Fig. 8. Dinámica poblacional de AVEFA (P: Plántula, VT: Vegetativo Temprano, VA: Vegetativo Avanzado, RI: Reproductivo Inicial) y factor de competencia (FC) de S3 – CASO OIV

Por su parte, S2 implementa la siembra de cebada en todo el horizonte de planeamiento y no realiza ningún tipo de control postemergente (Fig. 9). La combinación de estas medidas provoca un mayor crecimiento de la maleza, presentando un pico máximo de 255 ind/m² en 2015 y logrando, en general, un control más deficiente de AVEFA que en el caso anterior. Esto repercute en el rendimiento del cultivo y el margen bruto de la actividad, conduciendo al menor VPN del frente de Pareto, aunque presentando el menor impacto ambiental de todas las soluciones halladas.




Fig. 9. Dinámica poblacional de AVEFA (P: Plántula, VT: Vegetativo Temprano, VA: Vegetativo Avanzado, RI: Reproductivo Inicial) y factor de competencia (FC) de S2 – CASO OIV

4 Conclusiones

En este trabajo se desarrolló una herramienta de optimización mixta entera no lineal multiobjetivo (PSO MINLP-MO) como respuesta a la necesidad de explorar sistemáticamente la enorme cantidad de posibles estrategias de MIM en sistemas agronómicos. El sistema se ilustró con el control de *Avena fatua* L. en competencia con dos cereales de invierno (trigo y cebada) en un sistema productivo típico del sudoeste de la provincia de Buenos Aires.

Con la herramienta desarrollada se optimizaron dos casos de estudio, los cuales difieren entre sí tanto por las funciones objetivo adoptadas como por las restricciones impuestas. En todos ellos se consideraron el impacto económico y medioambiental para encontrar las soluciones más prometedoras en un horizonte de planeamiento de cinco años.

Los resultados de los dos casos de estudio presentados indican que: (i) mayoritariamente se prioriza la elección de cebada por sobre la de trigo en gran parte de los años; (ii) en el control presiembra, muchas soluciones alternan entre glifosato y labranza,

aunque las que mejor *VPN* logran son las que realizan mayormente barbecho químico; (iii) la aplicación de algún control postemergente, suelen conducir a mejores *VPN*.

En conclusión, el optimizador desarrollado aplicado sobre el modelo bio-económico constituye la base de una herramienta para guiar el complejo proceso de toma de decisiones de la actividad agrícola. Este sistema permite establecer el mejor esquema de rotación de cultivos y de tratamientos para controlar la maleza en función de la rentabilidad económica y el impacto medioambiental y presenta una lista de soluciones que residen en el frente de Pareto para que el tomador de decisión pueda inspeccionarlas y seleccionar la que mejor se adapte a su experiencia e intuición.

5 Referencias

1. Damiani L., Molinari, F. A., Blanco, A., & Chantre, G. R. (2020). Modelo de Simulación para el Manejo Integrado de Malezas: Análisis económico y medioambiental. In XII Congreso de AgroInformática (CAI)-JAIIO 49.
2. Chantre, G. R., & González-Andújar, J. L. (Eds.). (2020). Decision Support Systems for Weed Management. Springer International Publishing.
3. Damiani, L., Diaz, A. I., Iparraguirre, J., & Blanco, A. M. (2020). Accelerated particle swarm optimization with explicit consideration of model constraints. Cluster Computing, 149-164.
4. Marini, F., & Walczak, B. (2015). Particle swarm optimization (PSO). A tutorial. Chemometrics and Intelligent Laboratory Systems, 149, 153-165.
5. Kennedy, J., Eberhart, R. (1995). Particle swarm optimization (PSO). In Proc. IEEE International Conference on Neural Networks, Perth, Australia (pp. 1942-1948).
6. Zhang, H., & Rangaiah, G. P. (2012). An efficient constraint handling method with integrated differential evolution for numerical and engineering optimization. Computers & Chemical Engineering, 37, 74-88.
7. Pampara, G., Franken, N., & Engelbrecht, A. P. (2005). Combining particle swarm optimisation with angle modulation to solve binary problems. In 2005 IEEE congress on evolutionary computation (Vol. 1, pp. 89-96). IEEE.
8. Selçuklu, S. B., Coit, D. W., & Felder, F. A. (2020). Pareto Uncertainty Index for Evaluating and Comparing Solutions for Stochastic Multiple Objective Problems. European Journal of Operational Research.
9. Ferraro, D. O., Ghersa, C. M., & Sznaider, G. A. (2003). Evaluation of environmental impact indicators using fuzzy logic to assess the mixed cropping systems of the Inland Pampa, Argentina. Agriculture, Ecosystems & Environment, 96(1-3), 1-18.
10. Kovach, J; Petzold, C; Degnil, J y Tette, J. (1992). A method to measure the environmental impact of pesticides. New York's Food and Life Sciences Bulletin 139: 1-8.